

Classificação de Desempenho no ENEM com Base em Variáveis Socioeconômicas Usando Aprendizado de Máquina

Rafael Kenzo Sato Pires
Instituto de Ciência e Tecnologia
Universidade Federal de São Paulo (UNIFESP)
São José dos Campos, Brasil
rafael.kenzo@unifesp.br

Resumo—Este trabalho estuda se é viável classificar o desempenho de estudantes do ENEM em faixas (Baixo, Médio e Alto) utilizando exclusivamente variáveis socioeconômicas e demográficas. Foram aplicados três algoritmos de aprendizado de máquina, KNN, Decision Tree e Random Forest. Em uma amostra de 20.000 estudantes, o melhor resultado foi obtido pelo algoritmo Árvore de Decisão, com acurácia média de 48,32% e F1-Score Macro de 47,49%. O teste de Kruskal-Wallis confirmou diferença estatisticamente significativa entre os algoritmos ($H=32,9092$, $p<0.05$). Os resultados indicam que variáveis socioeconômicas possuem poder preditivo relevante, alinhando-se às ODS 4 e 10.

Index Terms—ENEM, aprendizado de máquina, fatores socioeconômicos, classificação, KNN, Árvore de Decisão, Random Forest, ODS

I. INTRODUÇÃO

O Exame Nacional do Ensino Médio (ENEM) é a principal forma de acesso a universidades de ensino superior no Brasil, servindo de acesso para faculdades públicas e em programas de bolsas e financiamentos estudantis. No entanto, as notas obtidas no exame frequentemente estão atrelados ao contexto socioeconômico, pela estrutura familiar e pelo investimento educacional. Como por exemplo, nos dados obtidos por Xavier e Rodrigues [1], ao analisar estatisticamente os microdados, comprovando uma forte associação entre a escolaridade dos pais e o desempenho dos filhos. Com isso surge este estudo, que tenta mostrar através de ML se é possível determinar as faixas de notas (baixa/média/alta) do aluno a partir de uma análise experimental comparativa de três algoritmos: KNN, Árvore de Decisão (Decision Tree) e Random Forest, de modo que, seus desempenhos foram avaliados ao longo de 30 execuções.

Para realização foi utilizado microdados do ENEM de 2023, dados esses que podem ser encontrados no site oficial do INEP, ou no caso do estudo retirado do Kaggle microdados reduzidos, foi utilizada uma amostra composta por 20.000 estudantes e variáveis socioeconômicas como renda familiar, escolaridade dos pais, tipo de escola e acesso à tecnologia.

O projeto alinha-se aos Objetivos de Desenvolvimento Sustentável da Agenda 2030 da ONU, atendendo a ODS 4 (Educação de Qualidade), focado na disparidade, e a ODS 10 (Redução das Desigualdades), ao utilizar técnicas de ML para tentar prever em qual média de nota o estudante se encaixa.

Este trabalho está organizado da seguinte forma: a Seção II apresenta os trabalhos relacionados; a Seção III descreve a metodologia adotada; a Seção IV apresenta os experimentos e resultados; e a Seção V traz as conclusões e trabalhos futuros.

II. TRABALHOS RELACIONADOS

Foram selecionados 5 artigos que foram utilizados para fomentar esse estudo dentre eles:

Xavier e Rodrigues [1] investigaram os efeitos socioeconômicos e parentais no desempenho no ENEM, utilizando uma análise estatística sobre microdados brasileiros de 2015 a 2023. Este trabalho foi selecionado no estudo, pois confirma empiricamente que variáveis socioeconômicas influenciam as notas, motivando o uso de ML para quantificar qual seria o poder preditivo.

Albreiki, Zaki e Alashwal [2] mostra como é feito a predição do desempenho de estudantes utilizando técnicas de aprendizado de máquina em larga escala. Destacando a alta eficiência de algoritmos clássicos como Árvores de Decisão, Random Forest e KNN para classificar estudantes em faixas de rendimento acadêmico. Esse artigo foi utilizado para fornecer um embasamento metodológico para a escolha dos modelos preditivos adotados.

Tertulino, Almeida e Alencar [3] desenvolveram uma análise preditiva do ENEM para o estado do Rio Grande do Norte, relacionando fatores socioeconômicos ao rendimento escolar. O trabalho utilizou modelos de ML para tentar prever o sucesso dos estudantes e também tratou de usar técnicas estatísticas para classificar o impacto de atributos como renda e tipo de escola. Tal pesquisa se assemelha em ideias com esse estudo, podendo ser um contraponto para o conjunto de dados de 20.000 escolhidos aleatoriamente dentre todas as regiões.

Jaloto e Prim [4] têm foco nas disparidades estruturais para o acesso à educação de qualidade no país. Os autores usaram variáveis ligadas à escolaridade dos pais, raça e bens de consumo impactando nos resultados dos exames. Este trabalho auxilia na fundamentação teórica do estudo ao detalhar aspectos da vulnerabilidade social, apoiando na escolha de variáveis socioeconômicas usadas, além de colocar um limite na discussão sobre o quanto esses fatores podem ser usados no modelo preditivo.

Banni, Oliveira e Bernardini [5] realizaram uma análise experimental com técnicas de Mineração de Dados Educacionais, em cima dos microdados do ENEM com o objetivo de identificar as causas relacionadas ao rendimento dos estudantes. O artigo envolveu o pré-processamento massivo dos dados do INEP e a aplicação de algoritmos de classificação do rendimento escolar. Possui relevância ao presente estudo, pois adota um protocolo experimental rigoroso de múltiplas execuções, servindo como um ponto de comparação direta para os resultados de acurácia, uso de baselines aleatórios e tempos de execução obtidos pelos classificadores.

III. METODOLOGIA

A. Conjunto de Dados

A pesquisa utiliza o Dataset microdados do ENEM 2023, disponibilizados pelo INEP, acessados via Kaggle. O conjunto de dados foi coletado a partir de uma amostra de 20.000 alunos e 12 parâmetros socioeconômicos sendo: Age, Genre, Race, School_Type, State, Region, Father_Education, Mother_Education, Family_Income, Has_Cell_Phone, Has_Computer, Has_Internet. Para classificação de desempenho foi dividida em 3 classes: **Baixo** (média < 500), **Médio** ($500 \leq \text{média} \leq 650$) e **Alto** (média > 650).

B. Configuração do Algoritmo e Ambiente Computacional

Os experimentos foram feitos no Google Colab com a linguagem Python, antes da execução de algoritmos foi necessário fazer um Pré-Processamento de variáveis string, como por exemplo foi preciso fazer um mapeamento das idades Under “17” e “26-30” que eram tratadas como strings, porém possuem ordem de grandeza. Dessa maneira, para evitar erros foi feito o mapeamento manualmente para números.

A distribuição inicial das três classes de desempenho apresentou desbalanceamento, com uma concentração de estudantes nas classes “Baixo” e “Médio”. Para tratar do problema aplicou-se a técnica de Random Undersampling, reduzindo o volume das classes majoritárias para balancear com a classe minoritária.

Na sequência, a base de dados tratada foi dividida utilizando 80/20. Dessa forma, 80% foram destinados ao conjunto de treino e 20% ao conjunto de testes. Essa abordagem foi essencial para evitar ter um ambiente distorcido.

C. Critérios de Análise

Na análise de dados, foram utilizadas 30 execuções de seeds diferentes. Foram coletadas duas métricas: Acurácia Geral e Macro F1-Score, e foi calculado suas médias, desvio padrão

e mediana. Com os resultados foi utilizado o teste Kruskal-Wallis para verificar se diferenças de desempenho entre os algoritmos são significativas.

IV. ANÁLISE EXPERIMENTAL

A. Conjunto de Dados

A Figura 1 apresenta a análise exploratória dos dados extraídos da amostra de 20.000 estudantes do ENEM 2023. No primeiro gráfico, observa-se a distribuição de alunos entre escolas privadas e públicas, evidenciando que a maioria dos candidatos provém de escolas públicas. O segundo é demonstrado a diferença entre a média de pontos em relação com a renda familiar, revelando um privilégio de pessoa com melhores condições familiares. Por fim, o último gráfico compara médias por regiões, evidenciando que a região Sudeste apresentou a maior média geral de notas, enquanto a região Norte registrou o menor rendimento, demonstrando as desigualdades estruturais e educacionais crônicas entre as regiões do país. Além dos fatores que foram graficados, a análise dos dados ocultos revelou que a infraestrutura é um fator de influência: candidatos sem acesso à internet ou sem um computador individual apresentaram um recuo severo em suas notas médias, concentrando-se predominantemente na faixa de desempenho classificada como “Baixo”.




Figura 1. Análise exploratória: tipo de escola, média por renda familiar e média por região.

B. Configuração e Tuning de Hiperparâmetros

Na Figura 2 é apresentado o processo de otimização de hiperparâmetros. Para o KNN o valor de vizinhos K = 21 foi o que maximizou a acurácia na partição de validação isolada, alcançando 45,42%. Para a Árvore de Decisão, profundidades máximas acima de 5 apresentaram uma estagnação seguida de queda no desempenho dos testes preliminares, indicando que uma árvore muito profunda passaria a memorizar ruídos do treino; portanto, fixou-se sua profundidade máxima de 5, obtendo a melhor acurácia prévia de 49,33%. Para o Random Forest, verificou que a partir de 50 árvores o ganho de acurácia tornou-se marginal e não justificava o custo computacional adicional, estabelecendo uma acurácia de 46,20%.




Figura 2. Otimização de hiperparâmetros: Árvore de Decisão (max_depth) e Random Forest (n_estimators).

C. Resultados e Discussão

Os resultados podem ser observados com base na Tabela I, obtida a partir de 30 execuções independentes.

Tabela I
RESUMO DAS MÉTRICAS APÓS 30 EXECUÇÕES

Algoritmo	Méd. Ac.	DP Ac.	Med. Ac.	Méd. F1
KNN (K=21)	0,4541	0,0070	0,4534	0,4526
Árvore (d=5)	0,4832	0,0290	0,4886	0,4749
Random Forest	0,4482	0,0079	0,4491	0,4440

Méd.=Média, DP=Desvio-Padrão, Med.=Mediana,
Ac.=Acurácia, d=max_depth

Concluindo a análise dos resultados, percebe-se que as acurácias dos três modelos ficam em torno de 44,82% e 48,32%. Esse resultado pode ser considerado relevante, uma vez que, se comparar com uma escolha aleatória “chute”, temos uma acurácia de apenas 33,33% (“Baixo”, “Médio”, “Alto”). O ganho de quase 15% de acerto obtido pelos modelos prova que as variáveis socioeconômicas e de infraestrutura sozinhas podem ser um fator que influencia de forma real o desempenho acadêmico do estudante. Porém, os acertos abaixo de 50% deixaram claro que fatores de esforço individual, qualidade de ensino e outros aspectos, que não foram captados no Dataset, desempenham um papel importante na nota final.




Figura 3. Matrizes de confusão dos três algoritmos com os melhores hiperparâmetros.




Figura 4. Distribuição de acurácia nas 30 execuções independentes.

O teste de Kruskal-Wallis resultou em $H = 32,9092$ e $p \approx 0,000$, rejeitando a hipótese nula e confirmando que as diferenças de desempenho entre os algoritmos são estatisticamente significativas ($p < 0,05$).

V. CONCLUSÃO

Este trabalho teve como objetivo ver se era possível classificar um estudante que prestasse a prova do ENEM em 3 faixas de notas, apenas analisando seus fatores socioeconômicos. Os resultados indicam que o algoritmo Árvore de Decisão apresentou o melhor desempenho, com uma acurácia média de 48,32% e F1-Score Macro 47,49%, destacando-se também pela eficiência ao ser até 26 vezes mais rápido que os demais modelos testados KNN e Random Forest.

Apesar de conseguir uma acurácia acima do esperado de uma escolha aleatória (33,33%), o estudo indica que apenas fatores socioeconômicos não são suficientes para determinar de forma precisa qual seria o desempenho médio do estudante, sendo ele influenciado por fatores além dos determinados no Dataset selecionado. Além disso, é importante ressaltar que o estudo focou nas ODS 4 (Educação de Qualidade) e 10 (Redução das Desigualdades) da Agenda 2030 da ONU, e conseguiu evidenciar que alunos com menor estrutura social apresentaram em sua maioria uma desvantagem, tendo em vista que apresentaram um menor preparo para o exame nacional do ensino médio.

Como trabalhos futuros, sugere-se a incorporação de variáveis adicionais como histórico escolar e qualidade do ensino, além da aplicação dos algoritmos sobre dados de múltiplos anos do ENEM para verificar se o poder preditivo das variáveis socioeconômicas se mantém consistente ao longo do tempo.

REFERÊNCIAS

- [1] C. C. Xavier e C. K. S. Rodrigues, “Socioeconomic and Parental Effects on ENEM Achievement: Evidence from Brazilian Microdata (2015–2023),” *Recent Advances in Evolution Education and Outreach*, v. 3, n. 1, p. 1–6, 2026.
- [2] B. Albreiki, N. Zaki e H. Alashwal, “A Systematic Literature Review of Student Performance Prediction Using Machine Learning Techniques,” *Education Sciences*, v. 11, n. 9, p. 552, 2021.
- [3] R. Tertulino, R. Almeida e L. Alencar, “Fatores Socioeconômicos e Desempenho Escolar: uma análise explicável e preditiva do ENEM no Rio Grande do Norte,” in *Anais do XIX ENIAC*, Porto Alegre: SBC, 2022, p. 458–469.

- [4] A. de A. Jaloto e R. Prim, “Fatores socioeconômicos associados ao desempenho no Exame Nacional do Ensino Médio,” *Estudos em Avaliação Educacional*, São Paulo, v. 33, e08573, p. 1–28, 2022.
- [5] M. B. F. Banni, L. C. Oliveira e F. Bernardini, “Uma Análise Experimental Usando Mineração de Dados Educacionais sobre os Dados do ENEM para Identificação de Causas do Desempenho dos Estudantes,” in *Anais do XXXII SBIE*, Porto Alegre: SBC, 2021, p. 742–752.